

Wniosek o Grant Obliczeniowy PLGrid

Paweł Pozorski, Jakub Muszyński

30 listopada 2025

Streszczenie

Tytuł projektu: Analiza wyjaśnialności multimodalnych i wielojęzycznych modeli językowych (MLLM) z wykorzystaniem wartości Shapleya

Słowa kluczowe: XAI, MLLM, Shapley Values, NLP, Audio processing, Large Language Models, Explainability

Celem projektu jest przeprowadzenie eksperymentalnej analizy wyjaśnialności (XAI) multimodalnych dużych modeli językowych (MLLM), przetwarzających zarówno tekst, jak i dźwięk. Badania stanowią kluczowy element pracy inżynierskiej realizowanej na Wydziale Matematyki i Nauk Informacyjnych Politechniki Warszawskiej.

Założenia projektu

Projekt zakłada wykorzystanie autorskiego pakietu `mllm-shap`¹ do estymacji wartości Shapleya (SV) dla modeli typu *audio-to-audio* oraz *text-audio*. Głównym celem badawczym jest zrozumienie, w jaki sposób informacje pochodzące z różnych modalności (tekst vs dźwięk) oraz języków (angielski, hiszpański, francuski) wpływają na decyzje modelu w konwersacjach wieloturowych. Badania obejmą analizę wpływu modalności wejścia/wyjścia na „skupienie” (*focus*) modelu oraz ocenę stabilności metod aproksymacji SV (Monte Carlo, alokacja Neymana) w kontekście danych multimodalnych.

Metodyka badań

Badania opierają się na metodach wyjaśnialności typu *black-box*, traktując model jako wyrocznię (bez dostępu do gradientów). Do obliczania atrybucji wykorzystane zostaną wartości Shapleya. Ze względu na wykładniczą złożoność obliczeniową dokładnego SV ($O(2^n)$), w projekcie zastosowane zostaną zaawansowane metody aproksymacji oparte na próbkowaniu:

1. **Estymatory Monte Carlo:** Warianty Standard oraz Limited (z wymuszeniem oceny koalicji pierwszego rzędu – *first-order omission*).
2. **Metoda Complementary Contributions (CC) z alokacją Neymana:** Wykorzystanie *stratified sampling* w celu redukcji wariancji estymatora przy ograniczonym budżecie obliczeniowym.

Eksperymenty zostaną przeprowadzone na przygotowanych podzbiorach danych **VoiceBench** oraz **InfinityInstruct** (warianty *single-sentence*, *multi-sentence*, *multi-turn*), każdy z nich w okolicach 100 rekordów. Budżet aproksymacji ustawiony zostanie na $4n^2$ gdzie n - ilość tokenów wejścia, dając maksymalnie 8,000 requestów do modelu dla każdego wejścia. Badane modele to m.in. Qwen2.5-Omni-3B, Baichuan-Audio (7B) oraz LFM2-Audio-1.5B.

¹<https://pawlo77.github.io/MLLM-Shap/>

Oprogramowanie

- Język: Python 3.10+
- Biblioteki ML/DL: PyTorch, Transformers (Hugging Face)
- Biblioteki pomocnicze: NumPy, Scikit-learn, Pandas
- Autorskie oprogramowanie: Pakiet `mllm-shap` (dostępne przez `pip install`).

Uzasadnienie zapotrzebowania na zasoby

Realizacja projektu wymaga znaczącej mocy obliczeniowej GPU ze względu na specyfikę metod wyjaśnialności opartych na wartościach Shapleya. Wyznaczenie atrybucji dla pojedynczej próbki danych wymaga wielokrotnego (rzędu setek lub tysięcy razy, w zależności od budżetu próbkowania) uruchomienia inferencji modelu dla różnych permutacji maskowania wejścia.

Zgodnie ze wstępnymi estymacjami przeprowadzonymi na lokalnej stacji roboczej (Nvidia RTX 4080), przetworzenie jednego zapytania do modelu zajmuje okolicę 2 s. Planowane eksperymenty są zatem wymagające, ponieważ zakładają:

- Analizę wartości Shapleya w zależności od modalności i języka. Powoduje to konieczność wielokrotnej iteracji zbiorów danych.
- Użycie modeli o większej liczbie parametrów (np. Baichuan-Audio 7B), co wymaga kart GPU o dużej pamięci VRAM (klasy A100) dla efektywnego przetwarzania wsadowego (*batching*) i uniknięcia błędów OOM (Out Of Memory).

Wstępne szacunki zasobów obliczeniowych dla budżetu $4n^2$ oraz planowanych eksperymentów są następujące:

- **single__sentence**: 100 próbek x 2 modalności wyjścia x 3 modalności wejścia per model. Dokładna liczba zapytań do modelu to 102,768.
- **multi__sentence**: 100 próbek x 4 konfiguracje modalności wejścia. Dokładna liczba zapytań do modelu to 814,416.
- **multi__lingual**: 108 próbek x 3 konfiguracje modalności wejścia. Dokładna liczba zapytań do modelu to 317,664.

Łącznie daje to około 1,234,848 zapytań do modelu. Przy średnim czasie przetwarzania 2 s na zapytanie, całkowity czas obliczeń wynosi około 2,469,696 s, czyli około 29 dni ciągłej pracy na pojedynczym GPU. Każdy eksperyment musi zostać wykonany na 3 różnych modelach, co daje łącznie około 87 dni pracy na pojedynczym GPU. Jest to wersja optymistyczna, ponieważ liczba tokenów audio może być większa niż tekstowych, oraz prędkość inferencji może się różnić w zależności od modelu i modalności wejścia (wybrane 2 są dla modelu LFM2-Audio-1.5B z wejściem tekstowym).

Dostęp do klastra obliczeniowego pozwoli na zrównoleglenie obliczeń dla różnych modeli i konfiguracji językowych, co jest niezbędne do ukończenia eksperymentów w ramach harmonogramu pracy dyplomowej.